

**UNIVERSIDADE FEDERAL DE SÃO CARLOS
CENTRO DE CIÊNCIAS EM GESTÃO E TECNOLOGIA
DEPARTAMENTO DE ECONOMIA
CURSO DE GRADUAÇÃO EM CIÊNCIAS ECONÔMICAS
ECONOMETRIA 2
PROF. DR. ADELSON MARTINS FIGUEIREDO**

**A RELAÇÃO DO ÍNDICE BOVESPA COM O ÍNDICE DAS ADR'S
BRASILEIRAS**

**ADEMIR DA SILVA JÚNIOR
CLÓVIS DANNEBROCK
FELIPY GEISSELMANN
MARCOS ÂNGELO PINTO ALVES**

Sorocaba

2019

Resumo

O objetivo do nosso trabalho é testar a existência do efeito contágio do índice Dow Jones Brazil Titans (BMF, 2000), informalmente conhecido como ADR20, sobre o índice Ibovespa no período de Junho de 2009 a Junho de 2019, com periodicidade mensal. Esse recorte de temporal foi selecionado pois asseguramos uma quantidade adequada de observações e ao mesmo tempo não trazemos o recorte da crise financeira ocorrida em 2008 para os dados da nossa série. O teste de cointegração de Johansen indica que não há relação de longo prazo entre as variáveis, e no curto prazo o impacto do índice ADR20 sob o Ibovespa não é significativo. Curiosamente, a relação inversa, do índice Bovespa sob o índice ADR20 é significativo. Temos como referência principal para o nosso trabalho o artigo *“Impactos do Índice Dow Jones, Commodities e Câmbio sobre o Ibovespa: uma análise do Efeito Contágio”*, Ruffy(2012).

Introdução

O mercado financeiro é um universo que contém todas as transações de derivativos para financiamento de, por exemplo: empresas, mercadorias, câmbio, juros e mobiliários. As operações de compra e venda de ativos financeiros também fazem parte desse imenso complexo, como este gigantesco ambiente engloba muitas instituições e investidores, o desenvolvimento de novas tecnologias e informações automatizadas com um processamento cada vez mais veloz faz com que algumas operações de grandes fundos de investimento ou tesouraria possam atuar na arbitragem da diferença de preços entre estes ativos.

Sendo este ambiente tão abrangente é evidente que variáveis serão influenciadas por outras variáveis de maneira que todas serão influenciáveis e influenciadoras, possibilitando a arbitragem por parte destes na diferença de preço entre os ativos.

O principal índice do mercado financeiro brasileiro é o Índice Bovespa que é o principal indicador do desempenho médio das cotações das ações no mercado brasileiro e que é calculado pela B3 (Brasil, Bolsa, Balcão) é a bolsa de valores brasileira. O principal índice do mercado financeiro norte americano é o Índice Dow Jones Industrial Average criado em 1986 pelo editor do “The Wall Street Journal” em comparação com o Índice Bovespa, ele representa uma das diversas bolsas dos Estados Unidos da América. As bolsas pelo qual são negociadas as ADR's brasileiras são a NYSE (New York Stock Exchange), AMEX (American Stock Exchange) e a NASDAQ Stock Market, ou simplesmente a bolsa eletrônica, um mercado automatizado onde estão listadas mais de 2800 ações de diferentes empresas, em sua maioria de pequena e média capitalização, sendo o segundo maior mercado de ações em capitalização de mercado do mundo, depois da Bolsa de Nova York.

Um de seus índices representa as ações brasileiras negociadas em Nova York, o Dow Jones Brazil Titans 20 Index (BR20) cuja função é a mesma no Índice Bovespa, porém este, voltado para as 20 ações brasileiras mais negociadas na bolsa americana por meio das American Depositary Receipt, criadas nos anos 20, estes Recibos Depositários Americanos foram

introduzidos no mercado com o objetivo de empresas estrangeiras conseguirem participar das grandes bolsas americanas. Desta forma, estas são compradas e vendidas no mercado americano, assim como diversos títulos regularmente, emitidos nos Estados Unidos da América seja por um banco, corretora ou instituições credenciadas, sendo o diferencial o fato de serem lastreadas a empresas estrangeiras.

Embora estes índices sejam para avaliar as ações dos mercados nacionais, este não se refere unicamente a empresas nacionais, há também diversas empresas estrangeiras inseridas no mercado financeiro de outros países, assim como empresas americanas na Ibovespa há empresas brasileiras com capital aberto na bolsa americana.

Baseado na importância do Índice Bovespa, neste trabalho temos a intenção de fazer inferências a fim de analisar se há a influência do Índice Bovespa no DJ Brazil Titans 20 ADR (BR20) (que é um índice das empresas brasileiras listadas na bolsa americana) ou vice-versa. O objetivo deste trabalho é buscar verificar algum efeito contágio entre essas duas variáveis: ADR's e ações brasileiras, através de seus índices correspondentes nos dois sentidos dentro de um período determinado.

Dados

A fonte de dados utilizada no trabalho foi baixada no site *tradingview*, utilizamos em nossa pesquisa as variáveis Ibovespa e índice ADR20, com periodicidade mensal, que vai de Junho de 2009 a Junho de 2019.

Modelo Analítico

O comportamento dinâmico das séries selecionadas para análise, (Ibovespa e Índice ADR20) podem ser analisadas por meio de um modelo econométrico VAR (vetores autorregressivos), que tem como principal característica a análise de inter-relações entre as variáveis (séries) escolhidas para compor o modelo. Ademais, o VAR possibilita a captação do valor defasado (lags) das variáveis. O modelo VAR foi desenvolvido Sims(1980), sendo uma proposta para solucionar problemas referentes aos modelos de equações múltiplas.

A leitura mais tradicional do modelo VAR geralmente ocorre pelo uso da função de resposta ao impulso. As estimativas realizadas por meio da função de resposta ao impulso permite que se faça avaliações dos resultados de choques em qualquer variável do sistema para que se verifique o impacto em outras.

A partir da estimação, é fácil visualizar graficamente o impacto de cada variável do sistema com relação às demais variáveis.

A formulação matemática do modelo VAR é expressada pela seguinte equação:

$$Y_t = A_1.Y_{t-1} + \dots + A_n.Y_{t-n} + \varepsilon_t \quad (1)$$

Y_t = representa o vetor de variáveis endógenas

$A_1 + \dots + A_n$ = matriz de coeficientes

ε_t = erro aleatório

Partindo da equação 1, podemos observar que as variáveis explicativas do sistema são as variáveis defasadas. Essa é uma das características do modelo VAR, ou seja, as variáveis do modelo são explicadas pelo seu próprio valor passado. Para os fins desse trabalho, estimamos um modelo VAR utilizando dados em periodicidade mensal utilizando os pontos dos respectivos índices (Ibovespa e ADR20). Os dados possuem amplitude de dez anos, a primeira observação se encontra em Junho de 2009 e vai até Junho de 2019. Esperamos que o período selecionado não contemple nenhuma quebra estrutural na série pois não contemplamos os efeitos da crise de 2008.

Utilizamos o software econométrico STATA 14 para estimar o modelo. Podemos destacar abaixo as séries que utilizamos em nossas estimativas:

1. Índice Ibovespa: utilizamos o índice Ibovespa à vista, em pontos, com a periodicidade mensal. É o principal índice do mercado brasileiro de ações e é

calculado a partir de uma carteira teórica, com 80% ativos mais líquidos do mercado, ou seja, aqueles que possuem maior volume de negócios.

2. Índice ADR20: utilizamos o índice ADR20 à vista, em pontos, com periodicidade mensal. O Dow Jones Brazil Titans 20 ADR Index, ou simplesmente ADR20 é um índice de ações que respresenta as 40 maiores empresas brasileiras listadas em ADR, ou seja, que estão listadas na bolsa americana. O ADR20 é um índice de Laspeyres, ou seja, ele mede a variação do preço contra uma quantidade fixada no período-base.

Procedimentos da modelagem VAR

O primeiro procedimento que tomamos ao iniciar o projeto é deixar a base de dados em logaritmo, processo que faz com que a série seja suavizada.

A modelagem VAR se inicia verificando se as séries são estudadas em nível ou na diferença, por meio dos resultados do teste de estacionariedade das séries. Após essa etapa, aplicamos outro teste para verificar a quantidade de defasagens (lags). Faremos, em seguida, o teste de cointegração para verificar se é ou não necessário adicionar um vetor de correção de erros (VEC). Também testamos a causalidade de granger para ver se a inclusão de uma variável ajuda ou não reduzir o erro de projeção de uma outra variável. E, finalmente, estimamos a função impulso à resposta e a decomposição da variância do erro de previsão das variáveis.

Para se verificar a estacionariedade da série, aplicamos o teste Dickey Fuller e o teste KPPS. O número de defasagens foi escolhida por meio do critério de Schwarz e Akaike. Para verificarmos a presença de cointegração entre as variáveis, fazemos o teste de Johansen. O teste de Johansen testa a hipótese nula de que não há cointegração contra a alternativa, de que há cointegração. Verificamos também a condição de estabilidade do nosso modelo, que nos mostra se as raízes estão dentro ou for a do círculo unitário. Aplicamos o teste de autocorrelação de Lagrange, que tem como hipótese nula a inexistência de autocorrelação para as ordens geradas pelo modelo.

Outros procedimentos de extrema importância que são efetuados em nosso trabalho são a estimação da função impulso à resposta e a

decomposição da variância do erro de previsão. A função de impulso à resposta mede o impacto de um choque de curto prazo em uma variável e a consequente resposta que essa causa em uma outra variável, já a decomposição da variância do erro de previsão nos mostra o quanto do erro de previsão provém de cada variável do modelo. Como podemos observar em Raffy(2012): “(...) *consiste na identificação da responsabilidade de cada uma das variáveis na explicação da variância do erro de previsão*”.

Também realizamos o teste de causalidade de Granger. Esse teste nos indica se uma variável *x granger causa* uma variável *y*, se essa relação for não rejeitada isso significa que as informações presentes e passadas da variável *x* ajudam a projetar o valor da variável *y*. A hipótese nula do teste é de que uma variável *x* não *granger causa* uma variável *y*.

Análise dos resultados

O primeiro resultado que analisamos é o que nos dá a quantidade de defasagens a ser utilizada nos testes Dickey-Fuller para testar a presença de raiz unitária. Os resultados nos indica que pelo teste de Newey-West haverá 4 lags e o teste de Schwert nos indica 12, como podemos ver no anexo A.

Com o resultado das defasagens, aplicamos o teste de Dickey-Fuller para testar a presença de raiz unitária. Pelos resultados encontrados, verificamos que as séries não são estacionárias, pois o valor da estatística do teste é maior do que os valores críticos considerando um α de 5%. Podemos verificar esses resultados no anexo B. Aplicamos também, para corroborar os resultados, o teste KPPS, que também realiza o teste de raiz unitária. Os resultados encontrados por meio desse teste reforçam o fato de que as séries não são estacionárias sem diferenciá-las, como podemos verificar no anexo C.

Sabendo da presença de raiz unitária, procedemos o teste Dickey-Fuller para as séries na primeira diferença. Assim nós testamos se a série é integrada na primeira diferença, ou seja, se ela é $I(1)$. Pelos resultados presentes no anexo D, podemos verificar que após para a primeira diferença as séries são estacionárias. Constatamos, portanto, que as séries são $I(1)$.

Na sequência fazemos o teste para verificar os lags que serão utilizadas no teste de cointegração de Johansen. Os quatro critérios indicam que a defasagem a ser utilizada para a estimação do teste de Johansen é 1, como mostra o anexo E.

O teste de cointegração de Johansen nos mostra o rank, e a partir desse resultados nos decidiremos como o modelo deverá estimado. Como podemos verificar pelo anexo F, para as três opções de modelagem (*trend*, *drift* e *noconstant*) nós encontramos que o rank é igual a zero, ou seja, o modelo VAR a ser efetuado posteriormente é na diferença. Isso significa que as variáveis devem receber uma diferenciação ao serem estimadas.

Ao estimarmos o modelo VAR na diferença com lag igual a 1, obtemos que o modelo é estável, porém há autocorrelação se considerarmos um α de 10%. Para corrigir o problema utilizamos lag igual a 2. Quando procedemos essa correção, a autocorrelação deixa de existir para qualquer nível de significância selecionado, como podemos ver pelo anexo G. Também no anexo G podemos verificar a estabilidade do modelo, que é confirmado pois as raízes se encontram dentro do círculo unitário.

Seguindo os testes, realizamos também o teste de causalidade de Granger, que podemos verificar no anexo H. O teste possui como hipótese nula que a variável *y* não *granger causa* a variável *x*. Como o p-valor dos testes é maior do que os níveis de significância, não rejeitamos a hipótese nula e portanto as variáveis não se *granger causam*.

Estimamos também as funções de impulso à resposta, nelas nós obtemos os choques de uma variável na outra. Pela tabela gerada que encontramos no anexo I, podemos verificar que as respostas da variável “libov” dado o que há um choque em “lbr20”. Obtivemos também os gráficos de impulso à resposta utilizando a ferramenta manual do STATA 14 seguindo os passos do tutorial de ([CrunchEconometrix](#), 2019). Verificamos que os choques de curto prazo das ADR20 no índice Ibovespa são quase nulos, sendo que na 12ª defasagem o impacto é de apenas $2,5e^{-6}$.

E por último nós estimamos a decomposição da variância do erro de previsão. Essa medida nos mostra o quanto da variância do erro advém de

cada variável do modelo, o resultado se encontra no anexo J. Pelo resultado verificamos que o impacto na variância do erro de previsão proveniente do “lbr20” que impacta no “libov” é não significativa, porém o impacto da “libov” no erro de previsão da “lbr20” já é significativo, fato que vai na direção da proposta inicial da nossa pesquisa.

O modelo pode ser observado no anexo H. Por possuir baixo R^2 muito baixo, podemos considerar que as séries não são boas para previsão e por isso não prosseguimos com as projeções. Os parâmetros do modelo também não são significativos a nenhum α crítico que possa ser selecionado.

Conclusão

O nosso objetivo inicial, que era verificar a existência do efeito contágio do índice ADR20 no índice Ibovespa não se mostrou consistente, pois o impacto da ADR20, no curto prazo, não é significativo sob o índice Ibovespa. O oposto, entretanto, foi observado. A nossa hipótese partia de uma curiosidade dos membros do grupo em verificar se os ativos brasileiros listados no maior e mais maduro mercado financeiro do mundo interferia nos preços dos ativos na bolsa nacional.

A inexistência do efeito contágio em relação a esses dois índices, no sentido de análise que propomos, não rejeitam, entretanto, que possa haver tal relação com outras séries. O que podemos pensar a partir dos resultados obtidos é que os preços das ADR's brasileiras são formadas mais a partir do resultado do índice nacional. O resultado também pode ter sido afetado pela periodicidade escolhida (mensal), os resultados utilizando dados *intraday* podem mostrar diferentes relações.

Referências bibliográficas

VARTANIAN, Pedro Raffy. Impactos do índice Dow Jones, commodities e câmbio sobre o Ibovespa: uma análise do efeito contágio. Revista de Administração Contemporânea, v. 16, n. 4, p. 608-627, 2012.

Sims, C. A. (1980a), Macroeconomics and Reality, Econometrica 48, 1–48.

Tradingview, 2019. Disponível em: <http://www.bmf.com.br/bmfbovespa/pages/boletim1/bd_manual/PDF/dowjones_guia.pdf>. Acesso em: 28 de jun. de 2019.

BMF, 2000. Disponível em: <<https://br.tradingview.com/>>. Acesso em: 28 de jun. de 2019.

CrunchEconometrix.(Stata13): VAR and Impulse Response Functions (2). 2019. (9m11s). Disponível em: <<https://www.youtube.com/watch?v=86ndMXvUP9k>>. Acesso em: 02 jul. 2019.

Anexo A

```
. *Gerando critério DE SCHWERT
.
. scalar defSW=abs(12*((T/100)^(1/4)))

. disp defSW
12.559622

. *GERANDO CRITÉRIO DE Newey-West
.
. *Tamanho da amostra T=120 para o teste ADF
.
. scalar T=120

. scalar defNW=abs(4*((T/100)^(2/9)))

. disp defNW
4.1653915
```

Anexo B

```
. dfuller libov, lags(4)trend regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

Test Statistic	Interpolated Dickey-Fuller		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-0.794	-4.035	-3.448
			-3.148

MacKinnon approximate p-value for Z(t) = 0.9662

```
. dfuller libov, lags(4) drift regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

Test Statistic	Z(t) has t-distribution		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-0.276	-2.361	-1.659
			-1.289

p-value for Z(t) = 0.3915

```
. dfuller libov, lags(4) noconstant regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

Test Statistic	Interpolated Dickey-Fuller		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	0.735	-2.598	-1.950
			-1.611

```
. dfuller lbr20, lags(4)trend regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

Test Statistic	Interpolated Dickey-Fuller		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-1.638	-4.035	-3.448
			-3.148

MacKinnon approximate p-value for Z(t) = 0.7770

```
. dfuller lbr20, lags(4) drift regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

Test Statistic	Z(t) has t-distribution		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-1.740	-2.361	-1.659
			-1.289

p-value for Z(t) = 0.0424

```
. dfuller lbr20, lags(4) noconstant regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 115

	Test Statistic	Interpolated Dickey-Fuller		
		1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-0.474	-2.598	-1.950	-1.611

Anexo C

```
. *TESTE KPSS
```

```
.
```

```
. kpss libov, notrend
```

KPSS test for libov

Maxlag = 12 chosen by Schwert criterion

Autocovariances weighted by Bartlett kernel

Critical values for H0: libov is level stationary

10%: 0.347 5% : 0.463 2.5%: 0.574 1% : 0.739

Lag order	Test statistic
0	3.27
1	1.69
2	1.16
3	.892
4	.731
5	.623
6	.546
7	.489
8	.444
9	.408
10	.378
11	.353
12	.332

```
. kpss lbr20, notrend
```

KPSS test for lbr20

Maxlag = 12 chosen by Schwert criterion

Autocovariances weighted by Bartlett kernel

Critical values for H0: lbr20 is level stationary

10%: 0.347 5% : 0.463 2.5%: 0.574 1% : 0.739

Lag order	Test statistic
0	6.49
1	3.32
2	2.25
3	1.71
4	1.39
5	1.18
6	1.02
7	.908
8	.82
9	.749
10	.691
11	.643
12	.602

Anexo D

```
. dfuller d.libov, lags(4)trend regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

Test Statistic	Interpolated Dickey-Fuller		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-6.123	-4.035	-3.448

MacKinnon approximate p-value for Z(t) = 0.0000

D2.libov	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
D.libov						
L1.	-1.373622	.224325	-6.12	0.000	-1.81832	-.9289239
LD.	.4104055	.1931609	2.12	0.036	.0274867	.7933244
L2D.	.1847049	.1666852	1.11	0.270	-.145729	.5151388
L3D.	.2213262	.126655	1.75	0.083	-.0297526	.472405
L4D.	.1221859	.0931043	1.31	0.192	-.0623824	.3067543
_trend	.0003456	.0001658	2.08	0.040	.0000168	.0006743
_cons	-.0163001	.0112663	-1.45	0.151	-.0386343	.006034

```
. dfuller d.lbr20, lags(4)trend regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

Test Statistic	Interpolated Dickey-Fuller		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-5.316	-4.035	-3.448

MacKinnon approximate p-value for Z(t) = 0.0001

D2.lbr20	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
D.lbr20						
L1.	-1.190948	.2240161	-5.32	0.000	-1.635034	-.7468624
LD.	.1633978	.1977209	0.83	0.410	-.2285609	.5553564
L2D.	.0361326	.171689	0.21	0.834	-.3042207	.376486
L3D.	.11948	.1340688	0.89	0.375	-.1462957	.3852557
L4D.	.0747466	.0944177	0.79	0.430	-.1124255	.2619187
_trend	.0002103	.0002446	0.86	0.392	-.0002746	.0006953
_cons	-.0165239	.0170958	-0.97	0.336	-.0504144	.0173666

```
. dfuller d.libov, lags(4)drift regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

Test Statistic	Z(t) has t-distribution		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-5.681	-2.361	-1.659

p-value for Z(t) = 0.0000

D2.libov	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
libov						
LD.	-1.240017	.218265	-5.68	0.000	-1.672656	-.8073779
LD2.	.3113148	.1900887	1.64	0.104	-.065474	.6881036
L2D2.	.1083241	.1651003	0.66	0.513	-.2189334	.4355815
L3D2.	.1780168	.1268557	1.40	0.163	-.0734332	.4294667
L4D2.	.0977928	.0937832	1.04	0.299	-.0881017	.2836874
_cons	.0044123	.0053833	0.82	0.414	-.0062584	.015083

```
. dfuller d.lbr20, lags(4)drift regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

Test Statistic	Z(t) has t-distribution		
	1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-5.264	-2.361	-1.659

p-value for Z(t) = 0.0000

D2.lbr20	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
lbr20						
LD.	-1.172055	.2226667	-5.26	0.000	-1.613419	-.7306911
LD2.	.1502408	.1968898	0.76	0.447	-.240029	.5405106
L2D2.	.0270065	.1711536	0.16	0.875	-.3122497	.3662627
L3D2.	.1150693	.1338088	0.86	0.392	-.150163	.3803016
L4D2.	.0721398	.0942551	0.77	0.446	-.1146901	.2589697
_cons	-.0035437	.0080135	-0.44	0.659	-.0194279	.0123405

```
. dfuller d.libov, lags(4)noconstant regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

	Test Statistic	Interpolated Dickey-Fuller		
		1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-5.632	-2.598	-1.950	-1.611

D2.libov	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
libov						
LD.	-1.210233	.2148944	-5.63	0.000	-1.636146	-.7843189
LD2.	.2867829	.1874347	1.53	0.129	-.0847066	.6582724
L2D2.	.0887865	.1631243	0.54	0.587	-.2345205	.4120935
L3D2.	.1651746	.1256947	1.31	0.192	-.0839481	.4142974
L4D2.	.0906544	.0932372	0.97	0.333	-.0941387	.2754475

```
. dfuller d.lbr20, lags(4)noconstant regress
```

Augmented Dickey-Fuller test for unit root Number of obs = 114

	Test Statistic	Interpolated Dickey-Fuller		
		1% Critical Value	5% Critical Value	10% Critical Value
Z(t)	-5.267	-2.598	-1.950	-1.611

D2.lbr20	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
lbr20						
LD.	-1.166658	.22151	-5.27	0.000	-1.605684	-.7276325
LD2.	.1467606	.1960052	0.75	0.456	-.2417153	.5352366
L2D2.	.0248215	.1704498	0.15	0.884	-.3130045	.3626475
L3D2.	.1143807	.1333051	0.86	0.393	-.1498256	.3785871
L4D2.	.0718782	.0939048	0.77	0.446	-.1142379	.2579944

Anexo E

```
. varsoc libov lbr20, maxlag(12)
```

Selection-order criteria

Sample: 2010m7 - 2019m6 Number of obs = 108

lag	LL	LR	df	p	FPE	AIC	HQIC	SBIC
0	7.11996				.003118	-.094814	-.074675	-.045145
1	371.187	728.14	4	0.000	4.0e-06*	-6.76273*	-6.70231*	-6.61372*
2	373.336	4.2965	4	0.367	4.1e-06	-6.72844	-6.62774	-6.48009
3	377.138	7.6045	4	0.107	4.1e-06	-6.72478	-6.5838	-6.37709
4	379.248	4.2198	4	0.377	4.3e-06	-6.68978	-6.50852	-6.24275
5	380.981	3.4669	4	0.483	4.5e-06	-6.6478	-6.42627	-6.10144
6	382.708	3.4543	4	0.485	4.6e-06	-6.60571	-6.3439	-5.96001
7	386.771	8.1251	4	0.087	4.6e-06	-6.60687	-6.30479	-5.86183
8	389.41	5.2779	4	0.260	4.8e-06	-6.58167	-6.2393	-5.73729
9	392.506	6.1918	4	0.185	4.9e-06	-6.56492	-6.18228	-5.62121
10	397.935	10.857*	4	0.028	4.8e-06	-6.59138	-6.16846	-5.54833
11	401.751	7.6336	4	0.106	4.8e-06	-6.58799	-6.12479	-5.4456
12	402.565	1.6274	4	0.804	5.1e-06	-6.52898	-6.02551	-5.28726

Endogenous: libov lbr20

Exogenous: _cons

Anexo F

```
. vecrank libov lbr20, trend(trend) lags(1) max
```

Johansen tests for cointegration

```
Trend: trend                                Number of obs =    119
Sample:  2009m8 - 2019m6                      Lags =      1
```

maximum				trace	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	4	410.33392	.	7.0817*	18.17
1	7	413.37159	0.04977	1.0064	3.74
2	8	413.87477	0.00842		

maximum				max	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	4	410.33392	.	6.0753	16.87
1	7	413.37159	0.04977	1.0064	3.74
2	8	413.87477	0.00842		

```
. vecrank libov lbr20, trend(const) lags(1) max
```

Johansen tests for cointegration

```
Trend: constant                                Number of obs =    119
Sample:  2009m8 - 2019m6                      Lags =      1
```

maximum				trace	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	2	408.01698	.	5.9462*	15.41
1	5	410.88647	0.04708	0.2072	3.76
2	6	410.99007	0.00174		

maximum				max	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	2	408.01698	.	5.7390	14.07
1	5	410.88647	0.04708	0.2072	3.76
2	6	410.99007	0.00174		

```
. vecrank libov lbr20, trend(none) lags(1) max
```

Johansen tests for cointegration

```
Trend: none                                Number of obs =    119
Sample:  2009m8 - 2019m6                      Lags =      1
```

maximum				trace	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	0	404.56509	.	11.3378*	12.53
1	3	409.63493	0.08168	1.1981	3.84
2	4	410.234	0.01002		

maximum				max	5%
rank	parms	LL	eigenvalue	statistic	critical value
0	0	404.56509	.	10.1397	11.44
1	3	409.63493	0.08168	1.1981	3.84
2	4	410.234	0.01002		

Anexo G

```
. varlmar, mlag(12)
```

Lagrange-multiplier test

lag	chi2	df	Prob > chi2
1	4.1669	4	0.38389
2	3.9609	4	0.41133
3	2.7979	4	0.59219
4	1.7163	4	0.78775
5	3.0823	4	0.54415
6	3.8650	4	0.42459
7	3.1781	4	0.52848
8	7.7331	4	0.10186
9	3.9785	4	0.40892
10	1.6692	4	0.79631
11	5.6026	4	0.23086
12	4.0605	4	0.39787

H0: no autocorrelation at lag order

```
. varstable
```

Eigenvalue stability condition

Eigenvalue	Modulus
-7.641e-17 + .3495997i	.3496
-7.641e-17 - .3495997i	.3496
.2373194	.237319
-.2373194	.237319

All the eigenvalues lie inside the unit circle.
VAR satisfies stability condition.

Anexo H

```
. vargranger
```

Granger causality Wald tests

Equation	Excluded	chi2	df	Prob > chi2
D_libov	D.lbr20	.77521	1	0.379
D_libov	ALL	.77521	1	0.379
D_lbr20	D.libov	.01488	1	0.903
D_lbr20	ALL	.01488	1	0.903

```
.
. granger d.libov d.lbr20, lag(1)
Granger Causality test (asymptotic) d.libov ---> d.lbr20,
H0: d.libov does not Granger-cause d.lbr20,
F( 1, 129) = .000025
Prob > F = .996
Granger Causality test
H0: d.libov does not Granger-cause d.lbr20,
chi2(1) = .00007674
Prob > chi2 = 0.9930


. granger d.lbr20 d.libov, lag(1)
Granger Causality test (asymptotic) d.lbr20 ---> d.libov,
H0: d.lbr20 does not Granger-cause d.libov,
F( 1, 129) = .02424089
Prob > F = .877
Granger Causality test
H0: d.lbr20 does not Granger-cause d.libov,
chi2(1) = .07441388
Prob > chi2 = 0.7850
```

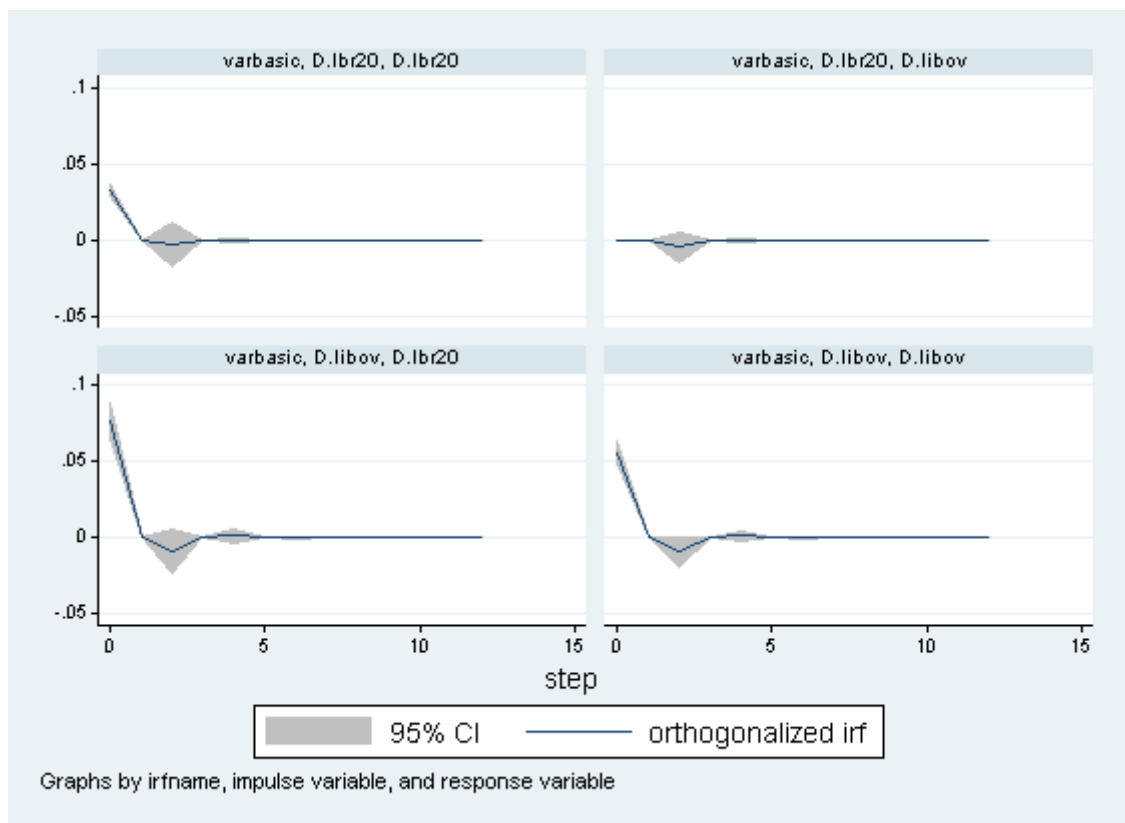
Anexo I

```
. irf table irf cirf, irf(ordem1) impulse(d.lbr20) response(d.libov) individual
```

Results from ordem1

step	(1) irf	(1) Lower	(1) Upper	(1) cirf	(1) Lower	(1) Upper
0	0	0	0	0	0	0
1	0	0	0	0	0	0
2	-.135155	-.436021	.16571	-.135155	-.436021	.16571
3	0	0	0	-.135155	-.436021	.16571
4	.008907	-.030636	.048449	-.126249	-.408765	.156267
5	0	0	0	-.126249	-.408765	.156267
6	-.001517	-.007536	.004502	-.127766	-.410159	.154627
7	0	0	0	-.127766	-.410159	.154627
8	.000161	-.000846	.001168	-.127605	-.410122	.154913
9	0	0	0	-.127605	-.410122	.154913
10	-.000021	-.000193	.000151	-.127626	-.410097	.154845
11	0	0	0	-.127626	-.410097	.154845
12	2.5e-06	-.000023	.000028	-.127623	-.410103	.154856





Anexo J

```
. irf table fevd
```

Results from ordeml

step	(1) fevd	(1) Lower	(1) Upper	(2) fevd	(2) Lower	(2) Upper	(3) fevd	(3) Lower	(3) Upper	step	(4) fevd	(4) Lower	(4) Upper
0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	1	1	1	.8438	.791803	.895798	0	0	0	1	.1562	.104202	.208197
2	1	1	1	.8438	.791803	.895798	0	0	0	2	.1562	.104202	.208197
3	.993815	.966365	1.02127	.844561	.79165	.897471	.006185	-.021265	.033635	3	.155439	.102529	.20835
4	.993815	.966365	1.02127	.844561	.79165	.897471	.006185	-.021265	.033635	4	.155439	.102529	.20835
5	.99379	.966224	1.02136	.844567	.791633	.897502	.00621	-.021357	.033776	5	.155433	.102498	.208367
6	.99379	.966224	1.02136	.844567	.791633	.897502	.00621	-.021357	.033776	6	.155433	.102498	.208367
7	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	7	.155432	.102497	.208367
8	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	8	.155432	.102497	.208367
9	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	9	.155432	.102497	.208367
10	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	10	.155432	.102497	.208367
11	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	11	.155432	.102497	.208367
12	.99379	.966223	1.02136	.844568	.791633	.897503	.00621	-.021356	.033777	12	.155432	.102497	.208367

95% lower and upper bounds reported

(1) irfname = ordeml, impulse = D.libov, and response = D.libov

(2) irfname = ordeml, impulse = D.libov, and response = D.lbr20

(3) irfname = ordeml, impulse = D.lbr20, and response = D.libov

(4) irfname = ordeml, impulse = D.lbr20, and response = D.lbr20

Anexo H

```
. var d.libov d.lbr20, lags(2)
```

Vector autoregression

```
Sample: 2009m10 - 2019m6      Number of obs   =      117
Log likelihood = 404.7204      AIC              = -6.815734
FPE            = 3.76e-06      HQIC           = -6.758226
Det(Sigma_ml) = 3.39e-06      SBIC           = -6.674084
```

Equation	Parms	RMSE	R-sq	chi2	P>chi2
D_libov	3	.056501	0.0354	4.287584	0.1172
D_lbr20	3	.084649	0.0119	1.404555	0.4955

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
D_libov						
libov						
L2D.	.015488	.2276728	0.07	0.946	-.4307425	.4617185
lbr20						
L2D.	-.1351554	.1535057	-0.88	0.379	-.4360211	.1657103
_cons	.0038907	.0053025	0.73	0.463	-.006502	.0142834
D_lbr20						
libov						
L2D.	-.0416036	.3410935	-0.12	0.903	-.7101345	.6269273
lbr20						
L2D.	-.0813875	.2299783	-0.35	0.723	-.5321367	.3693616
_cons	-.0020103	.007944	-0.25	0.800	-.0175804	.0135597